

REDES NEURAIIS ARTIFICIAIS: PRINCÍPIOS BÁSICOS

ARTIFICIAL NEURAL NETWORKS: BASIC PRINCIPLES

FLECK, Leandro¹; TAVARES, Maria Hermínia Ferreira²; EYNG, Eduardo³; HELMANN, Andrieli Cristina⁴; ANDRADE, Minéia Aparecida de Moares⁵

^{1,2}Universidade Estadual do Oeste do Paraná – UNIOESTE, Cascavel, Paraná, Brasil

^{3,4,5}Universidade Tecnológica Federal do Paraná – UTFPR, Medianeira, Paraná, Brasil

¹fleckmissal@gmail.com, ²mhstavar@gmail.com, ³eduardoe yng@utfpr.edu.br,

⁴andrieli.utfpr@hotmail.com, ⁵[mineia.moraes@hotmail.com](mailto:minea.moraes@hotmail.com)

Resumo

A atual capacidade computacional tem possibilitado o desenvolvimento constante de ferramentas de apoio à melhoria contínua dos processos industriais, onde as Redes Neurais Artificiais (RNAs) merecem especial destaque. Diante disso, o presente artigo tem como objetivo apresentar uma revisão bibliográfica acerca dos principais conceitos, características e princípios relacionados às RNAs, com enfoque em suas aplicações práticas. É possível identificar três classes de arquitetura de redes neurais fundamentalmente diferentes: redes alimentadas adiante com camada única, redes alimentadas diretamente com múltiplas camadas e redes recorrentes, sendo sua definição de fundamental importância para a eficiência do processo ao qual se destina. O processo de aprendizagem de uma RNA pode ocorrer de duas maneiras distintas: aprendizado supervisionado e aprendizado não supervisionado, tendo como principal diferença a presença ou não de um supervisor externo. Uma das principais vantagens da RNA é a capacidade de aprender e generalizar, ou seja, produzir saídas adequadas para entradas inexistentes durante o processo de aprendizagem. Em termos práticos a aplicação de uma RNA não ocorre de maneira simples, uma vez que, inúmeros problemas podem ocorrer durante o processo de implementação. Assim, pesquisas constantes são necessárias a fim de se chegar a uma arquitetura computacional que possibilite ampliar as atividades de modelagem, simulação e controle.

Palavras-chave: cérebro humano; inteligência artificial; neurônios; pesos sinápticos.

Abstract

The current computing power has enabled the constant development of tools to support continuous improvement of industrial processes, where the Artificial Neural Networks (ANN) deserves special focus. Therefore, this article aims to present a bibliographic review on the main concepts, features and principles related to ANNs, focusing on its practical applications. It is possible to identify three classes of architecture of neural networks fundamentally different: networks fed forward with single layer, networks fed directly with multiple layers and recurrent networks, being its definition of fundamental importance for the efficiency of the process to which it is intended. The learning process of ANN can occur in two distinct ways: supervised learning and unsupervised learning, having as main difference the presence or absence of an external supervisor. One of the main advantages of ANN is the ability to learn and generalize, ie, produce appropriate outputs for nonexistent entries during the learning process. In practical terms, the application of an ANN does not occur of simple manner, since several problems may occur during the deployment process. Thus, researches constants are needed in order to reach a computing architecture that enables expanding the activities of modeling, simulation and control.

Key-words: human brain; artificial intelligence; neurons; synaptic weights.

1. Introdução

Nos últimos anos tem se observado o desenvolvimento de processos industriais cada vez mais complexos, onde o desenvolvimento de tecnologias que norteiem a tomada de decisões tornou-se um fator decisivo para a inserção e manutenção de um produto ou serviço no mercado moderno. Neste âmbito, a modelagem matemática aliada a simulação de cenários futuros merece especial destaque, tendo em vista as múltiplas finalidades as quais se destina.

Na busca por um sistema de controle compatível com a complexidade da maioria dos processos industriais, várias pesquisas têm sido elaboradas de acordo com o desenvolvimento de novas ferramentas e tecnologias. Neste sentido, o uso de Redes Neurais Artificiais (RNAs) torna-se cada vez mais uma opção atrativa, haja vista a atual ampliação da capacidade computacional. Assim, Oleskovicz *et al.* (2003) afirmam que frente aos recentes avanços relacionados as técnicas de inteligência artificial, é possível encontrar na literatura diferentes modelos dessa natureza, voltados à solução de problemas específicos. A teoria de RNAs representa uma alternativa aos algoritmos tradicionais empregando métodos determinísticos.

Em sua forma mais geral, uma rede neural é um sistema projetado para modelar a maneira como o cérebro realiza uma tarefa particular, sendo normalmente implementada utilizando-se componentes eletrônicos ou é simulada por propagação em um computador digital. Para alcançarem bom desempenho, as redes neurais empregam uma interligação maciça de células computacionais simples, denominadas de “neurônios” ou unidades de processamento (HAYKIN, 2001).

O surgimento das RNAs deu-se com o modelo matemático do neurônio biológico proposto por Warren McCulloch e Walter Pitts em 1943 (McCULLOCH e PITTS, 1943). O

modelo, denominado neurônio MCP (McCulloch-Pitts), é descrito por um conjunto de n entradas, as quais são multiplicadas por um determinado peso e, em seguida, os resultados são somados e comparados a um limiar (NIED, 2007).

Em 1958, Frank Rosenblatt propôs uma topologia de rede denominada de percéptron constituída por neurônios MLP (Percéptrons de Múltiplas Camadas) e arranjada em forma de rede composta de duas camadas (ROSENBLATT, 1958), a qual possibilitou um aumento de trabalhos relacionados a redes neurais até 1969. Neste mesmo ano, a publicação de Minsky e Papert (MINSKY e PAPERT, 1969) mostrou deficiências e limitações do modelo MLP, provocando um desinteresse pelos estudos relacionados às RNAs. Somente a partir de 1982, com a publicação do trabalho de Hopfield (HOPFIELD, 1982), foi novamente despertado o interesse pelos estudos relacionados às redes neurais.

As RNAs são comumente utilizadas na resolução de problemas complexos, onde o comportamento das variáveis não é rigorosamente conhecido. Uma de suas principais características é a capacidade de aprender por meio de exemplos e de generalizar a informação aprendida, gerando um modelo não-linear, tornando sua aplicação na análise espacial bastante eficiente (SPÖRL *et al.*, 2011).

Em termos de topologia, para implementar uma RNA deve-se definir diferentes variáveis, dentre as quais: a) o número de nós na camada de entrada (tal variável corresponde ao número de variáveis que serão usadas para alimentar a rede neural, sendo normalmente as variáveis de maior importância para o problema em estudo), b) o número de camadas escondidas e o número de neurônios a serem colocados nessas camadas e, c) o número de neurônios na camada de saída (SANTOS *et al.*, 2005). Diante do exposto, o presente artigo tem como objetivo apresentar

uma revisão bibliográfica acerca dos principais conceitos, características e princípios relacionados às RNAs, com enfoque em suas aplicações práticas.

2. Arquitetura de RNAs

Uma das maiores dificuldades encontradas no uso das redes neurais é a escolha da melhor arquitetura, uma vez que esse processo é experimental e demanda um grande tempo de execução. Na prática, o processo deve ser aplicado com o intuito de testar vários métodos de aprendizado e as diferentes configurações que uma rede possa ter para a resolução de um problema em específico (MIRANDA *et al.*, 2009). Em geral, podemos identificar três classes de arquiteturas de rede fundamentalmente diferentes: redes alimentadas adiante com camada única, redes alimentadas diretamente com múltiplas camadas e redes recorrentes.

As RNAs são algoritmos computacionais que apresentam um modelo matemático inspirado na estrutura de organismos inteligentes, os quais possibilitam inserir simplificada o funcionamento do cérebro humano em computadores. Dessa forma, a exemplo do cérebro humano, a RNA é capaz de aprender e tomar decisões baseadas em seu próprio aprendizado. A RNA corresponde a um esquema de processamento capaz de armazenar conhecimento baseado em aprendizagem e disponibilizar este conhecimento para a aplicação à qual se destina (SPÖRL *et al.*, 2011).

De acordo com Haykin (2001), a rede neural se assemelha ao cérebro humano em dois aspectos básicos: a) o conhecimento é adquirido pela rede a partir de seu ambiente, por intermédio do processo de aprendizagem; b) forças de conexão entre neurônios (pesos sinápticos) são utilizadas para armazenar o conhecimento adquirido.

As redes neurais são compostas por uma

determinada quantidade de entradas e unidades de processamento, as quais são ligadas através de pesos sinápticos. As entradas são propagadas através da topologia da RNA, sendo transformadas pelos pesos sinápticos e pela função de ativação (AF) dos neurônios (MACHADO E FONSECA JÚNIOR, 2013). Recebendo entradas de n neurônios (y_i), o neurônio k calcula a sua saída através de:

$$y_k = AF \left(\sum_{i=1}^n (y_i w_{ki}) + b_k \right) \quad (1)$$

Onde:

Y_i é a saída calculada pelo neurônio i , W_{ki} representa o peso sináptico entre o neurônio i e o neurônio k e b_k é o peso entre um valor constante e diferente de zero ao neurônio k , conhecido como *bias*. Se o neurônio estiver ligado às entradas, o termo y_i é substituído pela entrada correspondente.

É necessário determinar os pesos sinápticos e *bias* para se utilizar uma RNA. A estimação de tais parâmetros, conhecida como treinamento, se constitui em um processo iterativo onde os parâmetros iniciais são utilizados até a convergência do processo. Considerando a interação j , o peso W_{ki} é utilizado através de:

$$w(j)_{ki} = w(j-i)_{ki} + \Delta w(j)_i \quad (2)$$

Com $\Delta w(j)_i$ sendo o vetor de correção ao parâmetro W_{ki} na iteração j .

Devido às características não-lineares inerentes ao mapeamento entre camadas de RNAs *feedforward*, estas se caracterizam como ferramentas de modelamento bastante apropriadas para o modelamento e controle de sistemas. Ferramentas matemáticas disponíveis para o controle de sistemas não-lineares

normalmente utilizam técnicas de linearização, transformando a tarefa de controle não-linear em pequenas tarefas de controle linear. Apesar de muitas vezes eficiente, esta abordagem não retrata a realidade dos sistemas físicos, podendo resultar em soluções subótimas. Devido à capacidade de modelar com fidelidade ações não lineares, as RNAs se constituem uma importante ferramenta para o controle de sistemas (BRAGA, 2000).

De acordo com Braga *et al.* (2007) um modelo básico de RNA possui diferentes componentes, dentre os quais:

- Conjunto de sinapses: conexões entre os neurônios da RNA. Cada uma delas possui um peso sináptico;
- Integrador: realiza as somas dos sinais de entrada da RNA, ponderados pelos pesos sinápticos;
- Função de ativação: restringe a amplitude do valor de saída de um neurônio;
- Bias: valor aplicado externamente a cada neurônio e tem o efeito de aumentar ou diminuir a entrada líquida da função de ativação.

2.1 Função de ativação

O modelo de cada unidade da rede pode incluir uma não-linearidade na sua saída, a qual deve ser reduzida. A função de ativação representa o efeito que a entrada interna e o estado atual de ativação exercem na definição do próximo estado de ativação da unidade. Segundo Haykin (2001) existem diversos tipos de funções de ativação, sendo as mais populares:

- Função limiar: normalmente restringe a saída da RNA em valores binários [0,1]. A saída do neurônio assume valor 0 quando seu resultado for negativo, e 1 caso contrário (Figura 1a), sendo representada por:

$$f(u) = \begin{cases} 1 & \text{se } u \geq 0 \\ 0 & \text{se } u < 0 \end{cases} \quad (3)$$

- Função linear por partes: pode ser vista como uma aproximação de um amplificador não-linear (Figura 1b), representada por:

$$f(u) = \begin{cases} 1 & \text{se } u \geq +1/2 \\ u & \text{se } +1/2 > u > -1/2 \\ 0 & \text{se } u \leq -1/2 \end{cases} \quad (4)$$

Na função linear por partes assume-se que o fator de amplificação dentro da região linear de operação é a unidade. As seguintes situações podem ser vistas como formas especiais da função linear por partes: a) se a região linear de operação é mantida sem entrar em saturação, surge um combinador linear; b) a função linear por partes se reduz à função limiar, se o fator de amplificação da região linear é infinitamente grande.

- Função sigmoide: trata-se da função mais comum. É definida como uma função crescente com balanceamento adequado entre o comportamento linear e não linear e assume um intervalo de variação entre 0 e 1 (Figura 1c). Um exemplo de função sigmoide é a função logística, definida por:

$$f(\mu) = \frac{1}{1 + \exp(-a\mu)} \quad (5)$$

sendo a o parâmetro de inclinação da função sigmoide (quanto maior o valor de a , mais inclinada se torna a curva).


- Função tangente hiperbólica: pelo fato da função logística apresentar valores de ativação apenas no intervalo (0, 1), em muitos casos ela é substituída pela função tangente hiperbólica, que preserva a forma

sigmoidal da função logística, mas assume valores positivos e negativos. Para a forma correspondente de uma função sigmóide, podemos utilizar a função tangente hiperbólica, dada por:

$$f(u) = \tanh(u) \quad (6)$$

O fato de se permitir que uma função de ativação do tipo sigmóide assumam valores negativos como descrito pela Equação (6), em alguns casos traz benefícios analíticos.

Figura 1- (a) função limiar. (b) função linear por partes. (c) função sigmoide com parâmetro de inclinação a variável.



3. Aprendizagem e treinamento de RNAs

A aprendizagem de uma rede neural é um processo onde os parâmetros livres são adaptados através de um processo de estimulação pelo ambiente em que a rede está inserida. Com isso, o tipo de aprendizagem é determinado com base na maneira pela qual a modificação dos parâmetros ocorre. Em síntese, tem-se a seguinte sequência de eventos: a) a rede neural é estimulada por um ambiente; b) a rede neural sofre modificações nos seus parâmetros livres como resultado desta estimulação; c) a rede neural responde de uma maneira nova ao ambiente, devido às modificações ocorridas na sua estrutura interna (HAYKIN, 2001).

O aprendizado de uma RNA é realizado por meio de processos iterativos de ajustes aplicados aos pesos sinápticos, o chamado treinamento. O aprendizado só ocorre quando a rede neural atinge uma solução generalizada para um determinado problema. Em síntese, treinar uma rede é ajustar a sua matriz de pesos sinápticos de forma que o vetor de saída coincida com um valor desejado para cada vetor de entrada (MIRANDA *et al.*, 2009).

Na fase de aprendizagem a RNA extrai informações relevantes de padrões de informação apresentados a ela, dando origem a uma representação própria do problema. Nesta etapa, os parâmetros da rede são ajustados, os quais são caracterizados pelos pesos das conexões entre as unidades de processamento. Ao final da etapa de treinamento, a rede terá adquirido conhecimento sobre o ambiente em que está operando, sendo este, “armazenado” em seus parâmetros (Eyng, 2008).

As RNAs podem ser diferenciadas quanto à forma de aprendizagem, usando os seguintes paradigmas (BISHOP, 1995):

- Aprendizagem supervisionada: um supervisor externo fornece à RNA a saída desejada em relação a um padrão de entrada. Com isso, é

possível comparar a saída da RNA com a saída desejada, obtendo-se o erro referente à resposta atual. A partir disso, os pesos sinápticos são ajustados de forma a minimizar o erro. A minimização do erro é incremental, pois a cada resposta gerada pela rede, são efetuados pequenos ajustes nos pesos das conexões.

- **Aprendizado não supervisionado:** não existe um supervisor acompanhando o processo de aprendizagem. Diante disso, a RNA deve procurar algum tipo de correlação ou redundância nos dados de entrada.

Quando as RNAs são utilizadas na modelagem de processos, é usual utilizar-se o aprendizado supervisionado. A implementação deste método, pode ser feita *off-line* ou *on-line*. No primeiro caso, os dados do conjunto de treinamento não mudam, e caso seja necessário à inclusão de novos dados, um novo banco de dados destinado ao treinamento deve ser elaborado, contendo os dados antigos e novos. No segundo caso, a rede opera em constante processo de adaptação, sendo atualizada constantemente (EYNG, 2008).

A RNA pode ser treinada e validada segundo o critério de erro máximo e, posteriormente ser utilizada como modelo do sistema em análise, com garantia de que, se utilizada dentro de uma determinada faixa de operação, a mesma não incorrerá em erros maiores que o erro máximo previsto (ALVES SOBRINHO *et al.*, 2011).

De acordo com Ambrósio (2002) a aprendizagem por correção do erro, consiste em ajustes nos pesos das conexões entre os neurônios da rede, baseados nos erros encontrados nos sinais de saída, com o objetivo de minimizar esse erro. O erro da saída consiste na diferença entre o resultado calculado pelo neurônio e o resultado desejado. Para tanto, por intermédio de uma fonte externa, é necessário fornecer diretamente à rede as respostas desejadas para cada padrão de entrada

apresentado durante a fase de treinamento. Matematicamente, esse sinal de erro é definido por:

$$e_j(n) = d_j(n) - y_j(n) \quad (7)$$

Onde, o sinal de erro e do neurônio j no instante n (passo de tempo do processo de iteração envolvido na aprendizagem) é igual a saída desejada (d) para esse neurônio menos a sua saída efetivamente obtida.

4. Perceptrons de múltiplas camadas (MLP)

O perceptron, introduzido por Rosenblatt, em 1958, é uma forma simples de RNA cuja principal aplicação se dá nos problemas de classificação de padrões. O perceptron de camada única só é capaz de classificar padrões linearmente separáveis. Na prática, o problema a ser trabalhado não admite uma separação linear exata, tornando-se necessário o uso de um perceptron multicamadas (AMBRÓSIO, 2002).

As arquiteturas do tipo MLP constituem os modelos neurais artificiais mais utilizados e conhecidos. Uma rede MLP é subdividida em camadas: camada de entrada, camada(s) intermediária(s) ou escondida(s) e camada de saída (NIED, 2007). De acordo com Machado e Fonseca Junior (2013), na arquitetura da RNA de múltiplas camadas as entradas são prolongadas da camada de entrada para a camada de saída, passando por uma ou mais camadas ocultas.


Neste mesmo sentido Santos *et al.* (2005), afirmam que uma rede neural multicamadas é tipicamente composta de camadas alinhadas de neurônios. A camada de entrada distribui as informações de entrada para a(s) camada(s) escondida(s) da rede. Na camada de saída, a solução do problema é obtida. As camadas escondidas são camadas

intermediárias, que têm como função separar as camadas de entrada e de saída. Os neurônios de uma camada estão conectados apenas aos neurônios da camada imediatamente posterior, não havendo realimentação, nem conexões entre neurônios da mesma camada. Além disso, caracteristicamente, as camadas são totalmente conectadas.

Na Figura 2 é possível observar uma

arquitetura do tipo MLP com duas camadas intermediárias. A rede apresentada possui todas as conexões, o que significa que um neurônio em qualquer camada da rede está conectado a todos os outros neurônios na camada anterior. O fluxo de sinais através da rede é feito positivamente, da esquerda para a direita, camada a camada.

Figura 2- Arquitetura MLP com duas camadas intermediárias.



A aprendizagem de redes MLP por retropropagação (algoritmo BP) consiste de duas etapas: a propagação e a retropropagação. Na etapa de propagação, um padrão de ativação é aplicado aos nós da camada de entrada da rede e seu efeito se propaga através da rede, camada por camada. Na última camada, um conjunto de saídas é produzido, configurando-se como resposta real da rede. Na etapa de retropropagação, todos os pesos sinápticos são ajustados de acordo com uma regra de correção de erro. O sinal de erro é propagado para trás através da rede, contra a direção das conexões sinápticas, sendo os pesos sinápticos ajustados para fazer com que a resposta real da rede se aproxime da resposta desejada, num sentido estatístico (NIED, 2007).

De acordo com Ambrósio (2002), uma característica importante de redes MLP é a não

linearidade das saídas dos neurônios. Essa não linearidade é obtida utilizando-se como função de ativação uma função do tipo sigmoide, normalmente a função logística, apresentada na equação 5.

5. Principais benefícios e desvantagens das RNAs

Uma RNA extrai seu poder computacional através de sua habilidade de aprender e de generalizar. A generalização se refere ao fato de a rede neural produzir saídas adequadas para entradas inexistentes durante a aprendizagem, tornando possível a resolução de problemas complexos, atualmente intratáveis. Entretanto, as redes neurais precisam ser integradas em uma abordagem consistente de engenharia de sistemas, onde um problema

complexo é decomposto em um número de tarefas relativamente simples, de acordo com a capacidade inerente à RNA (HAYKIN, 2001).

De acordo com Haykin (2001) o uso das redes neurais oferece as seguintes capacidades:

- Não-linearidade: um neurônio artificial pode ser linear ou não-linear. A não-linearidade é distribuída por toda a rede. Se o mecanismo responsável pela geração do sinal de entrada for inerentemente não-linear, a não-linearidade torna-se uma propriedade muito importante.
- Adaptabilidade: as redes neurais possuem a capacidade de adaptar seus pesos sinápticos a modificações do meio ambiente. Assim, uma rede neural treinada para operar em um ambiente específico pode ser retreinada para lidar com pequenas alterações nas condições operativas do ambiente.
- Resposta a evidências: no contexto de classificação de padrões, uma rede neural pode ser projetada para fornecer informações sobre a confiança ou crença na decisão tomada, possibilitando rejeitar padrões ambíguos e, por consequência, melhorar o desempenho de classificação da rede.
- Informação contextual: O conhecimento é representado pela estrutura e estado de ativação de uma rede neural. Cada neurônio da rede é potencialmente afetado pelas atividades de todos os outros neurônios na rede. Dessa forma, a informação contextual é tratada naturalmente pela rede.
- Tolerância a falhas: uma rede neural, implementada em *hardware*, tem como característica a tolerância a falhas. Entretanto, para se assegurar que uma rede neural seja de fato tolerante a falhas pode ser necessário adotar-se medidas corretivas no projeto do algoritmo utilizado para treiná-la.
- Análise neurobiológica: o projeto de uma rede neural é motivado pela analogia com o cérebro humano, sendo esta uma prova viva

de que o processamento paralelo tolerante a falhas é possível fisicamente, rápido e poderoso. Os neurobiólogos encaram as RNAs como ferramentas de pesquisa para a interpretação de fenômenos neurobiológicos e os engenheiros olham para a neurobiologia buscando ideias para a resolução de problemas mais complexos do que aqueles baseados em técnicas convencionais de projeto por conexões fixas.

Ambrósio (2002) ressalta que além das inúmeras vantagens supracitadas, existem algumas desvantagens relacionadas à utilização das redes neurais, dentre as quais:

- Treinamento demorado: dependendo da aplicação da rede neural, o treinamento pode ser demorado, demorando horas ou mesmo dias.
- Resultados desconcertantes: as redes podem chegar a conclusões contrárias às teorias aceitas, onde somente o bom senso do pesquisador poderá solucionar tal problema.
- Caixa-preta: não é possível saber o motivo que levou a rede a uma determinada conclusão.
- Grande volume de dados: para o correto aprendizado da rede, é necessário um grande volume de dados históricos, o que pode demandar tempo e recursos.
- Preparação dos dados: os dados de entrada da rede neural necessitam de tratamento prévio como, por exemplo, a normalização e seleção criteriosa, a fim de obter resultados confiáveis.

6. Principais aplicações de RNAs

A utilização da RNA para um fim específico tem relação direta com a eficiência com que esta fornece respostas próximas aos dados de saída reais. Para isso, o neurônio artificial deve ser capaz de aprender uma determinada tarefa (EYNG, 2008).

De acordo com Eyng *et al.* (2009) e

Eyng e Fileti (2010), ao aplicar um controlador *feedforward-feedback*, baseado em RNAs, a um processo de produção de etanol por fermentação, cujas características também indicam a não-linearidade do sistema, os resultados foram muito satisfatórios, superando a estratégia de controle tradicional (linear), baseada em um controlador Proporcional Integral Derivativo (PID).

Salviano (2002) realizou a modelagem do processo de tratamento de efluentes orgânicos visando à predição da concentração de nitrogênio em um reator biológico, fornecendo dados ao operador para controle da dosagem de hidróxido de amônio (NH_4OH), com o intuito de evitar o excesso de nitrogênio lançado no curso hídrico receptor. Como os fenômenos que ocorrem no reator biológico são de difícil modelagem fenomenológica e, diante de uma extensa base de dados coletados, com informações das variáveis de entrada e saída de interesse, optou-se pela modelagem via RNAs. Foram definidas onze variáveis de entrada e uma variável de saída (concentração de nitrogênio no seio do reator), formando uma arquitetura da rede neural de 11 neurônios na camada de entrada, 27 na camada oculta e 1 na camada de saída. Utilizando o modelo neural treinado para simular a estação de tratamento de efluentes, detectou-se a realização de um procedimento operacional (adição de anti-espumante ao reator biológico) que resultava em aumentos bruscos da concentração de nitrogênio. Diante da informação obtida foi possível eliminar a adição de anti-espumante ao reator, permitindo uma melhor estabilização da estação de tratamento.

Alves Sobrinho *et al.* (2008) elaboraram uma RNA para estimar a evapotranspiração de referencia (Eto) em função de dados diários de temperatura do ar. A RNA foi treinada tomando-se por referência a Eto diária obtida pelo método de Penman-Monteith. Nas camadas intermediárias foram utilizadas funções de ativação do tipo tan-sigmóide, e nas

camadas de saída funções de ativação do tipo lineares. Os valores de Eto gerados pela RNA foram comparados com os obtidos pelos métodos de Blanney-Criddle e Hargreaves, considerando meses referentes a todas as estações do ano. O desempenho da RNA desenvolvida foi considerado satisfatório, representando um método indireto para estimativa da evapotranspiração, com custos reduzidos na aquisição de dados para a estimativa dessa variável.

Santos *et al.* (2005) desenvolveram um sistema para predição da soroprevalência da Hepatite A, considerando modelos de regressão de logística e RNAs, sendo seus desempenhos mensurados pela taxa de classificação incorreta em uma amostra do município de Duque de Caxias (RJ), o qual apresenta elevada prevalência da doença. Os resultados obtidos mostraram que o modelo neural, aplicado sobre a informação relevante extraída do modelo de regressão logística, apresenta um bom desempenho, alcançando uma eficiência de classificação geral acima de 88%.

7. Considerações finais

As RNAs configuram-se como uma tecnologia embasada em raízes multidisciplinares, sendo fundamentada pela neurociência, matemática, física, estatística, ciência da computação e engenharia. Como resultado do acelerado desenvolvimento tecnológico, as redes neurais passaram a ter aplicações em diferentes campos como, por exemplo, em processos de modelagem, análise de séries temporais, reconhecimento de padrões, processamento de sinais e controle de processos. Uma das principais características que fundamentam sua ampla aplicabilidade é a habilidade de aprender a partir de dados de entrada com ou sem a supervisão de um professor.

Para que a rede neural forneça resultados satisfatórios, além de uma arquitetura adequada,

o processo de treinamento e validação deve ser efetuado com qualidade. Dessa forma, se faz necessário fornecer à rede dados representativos da dinâmica do processo, onde a determinação destes valores deve ser efetuada de modo a propiciar uma rede que forneça bons resultados sem que haja um esforço computacional excessivo.

Na prática, a aplicação das redes neurais não ocorre de maneira tão simples. Inúmeros problemas podem ocorrer durante o seu processo de implementação, podendo restringir sua aplicação em situações específicas. Além disso, as RNAs normalmente não conseguem fornecer soluções precisas quando aplicadas isoladamente, sendo integradas a outros tipos de sistemas. Assim, pesquisas constantes são necessárias a fim de se chegar a uma arquitetura computacional que possibilite ampliar as atividades de modelagem, simulação e controle.

8. Referências

ALVES SOBRINHO, T.; RODRIGUES, D. B. B.; OLIVEIRA, P. T. S.; REBUCCI, L. C. S.; PERTUSSATTI, C. A. Estimativa da evapotranspiração de referência através de redes neurais artificiais. **Revista Brasileira de Meteorologia**, v.26, n.2, p. 197-203, 2011.

AMBRÓSIO, P. E. **Redes neurais artificiais no apoio ao diagnóstico diferencial de lesões intersticiais pulmonares**. 2002. Ribeirão Preto – SP. Dissertação (Mestrado) – Faculdade de Filosofia, Universidade de São Paulo.

BISHOP, C. M. **Neural networks for Pattern Recognition**. Clarendon Press, Oxford, 1995.

BRAGA, A. de.; LUDERMIR, T. B.; CARVALHO, A. C. P. de L. F. **Redes Neurais Artificiais teoria e aplicações**, Rio de Janeiro: LTC – Livros Técnicos e Científicos Editora S.A., 2000.

BRAGA, A. P.; LUDENIR, T. B.; CARVALHO, A. C. P. L. F. **Redes Neurais Artificiais: teorias e aplicações**. Livros Técnicos e Científicos, Rio de Janeiro. 2007.

EYNG, E. **Controle Feedforward-Feedback aplicado às colunas de absorção de produção de etanol por fermentação**. 2008. Campinas, SP. Tese (Doutorado) – Programa de Pós-Graduação em Engenharia Química,

Universidade Estadual de Campinas.

EYNG, E.; FILETI, A. M. F. Control of absorption columns in the bioethanol process: Influence of measurement uncertainties. **Engineering Applications of Artificial Intelligence**, v. 23, p. 271-282, 2010.

EYNG, E.; SILVA, F. V.; PALÚ, F.; FILETI, A. M. F. Neural Network Based Control of an Absorption Column in the Process of Bioethanol Production. **Brazilian Archives of Biology and Technology**, v. 52, p. 961-972, 2009.

HAYKIN, S. **Redes Neurais- Princípios e Práticas**. BOOKMAN, São Paulo, 2ª ed. 2001. 900 p.

HOPFIELD, J. J. Neural networks and physical systems with emergent collective computational abilities. **Proceedings of the National Academy of Science of the USA**. v.79, n.8, p.2554-2558, 1982.

MACHADO, W. C.; FONSECA JÚNIOR, E. S. Redes Neurais Artificiais aplicadas na previsão do VTEC no Brasil. **Boletim de Ciências Geodésicas**, v.19, n.2, p. 227-246, 2013.

McCULLOCH, W.; PITTS, W. A logical calculus of the ideas immanent in nervous activity. **Bulletin of Mathematical Biophysics**, v.5, p.115-133, 1943.

MINSKY, M. L.; PAPERT, S. A. **Perceptrons**, MIT Press, Cambridge, MA. 1969.

MIRANDA, F. A.; FREITAS, S. R. C.; FAGGION, P. L. Integração e interpolação de dados de anomalias ar livre utilizando-se a técnica de RNA e krigagem. **Boletim de Ciências Geodésicas**, v.15, n.3, p. 428-443, 2009.

NIED, A. **Treinamento de redes neurais artificiais baseado em sistemas de estrutura variável com taxa de aprendizagem adaptativa**. 2007. Belo Horizonte, MG. Tese (Doutorado) – Programa de Pós-Graduação em Engenharia Elétrica, Universidade Federal de Minas Gerais.

OLESKOVICZ, M.; COURY, D. V.; AGGARWAL, R. K. O emprego de Redes Neurais Artificiais na detecção, classificação e localização de faltas em linhas de transmissão. **Revista Controle e Automação**, v.14, n.2, p. 138-150.

ROSENBLATT, F. The perceptron: A probabilistic model for information storage and organization in the brain. **Psychological Review**, v.65, n.6, p. 386-408, 1958.

SALVIANO, F. O. C. **Modelagem e simulação de um tratamento de efluentes orgânicos através de redes neurais**. 2002. Campinas, SP. Dissertação (Mestrado) – Faculdade de Engenharia Química, Universidade Estadual de Campinas.

SANTOS, A. M.; SEIXAS, J. M.; PEREIRA, B. B.; MEDRONHO, R. A. Usando Redes Neurais Artificiais e Regressão Logística na predição da Hepatite A. **Revista Brasileira de Epidemiologia**, v.8, n.2, p. 117-126, 2005.

Geografia, v. 21, n.1, p. 113-135, 2011.

Artigo submetido em: 20.06.2015

SPÖRL, C.; CASTRO, E. G.; LUCHIARI, A. Aplicação de Redes Neurais Artificiais na construção de modelos de fragilidade ambiental. **Revista do Departamento de**

Artigo aprovado para publicação em: 21.03.2016